A1 한 번의 집계로 연합학습을 평가할 수 있는가?

1회 집계에서 모델 간 차이를 비교했다. 여러 시드·라운드의 수렴과 재현성은 검증하지 않았다.

근거 1 | 같은 1 epoch여도 학습량은 다름

학습 대상	학습 쌍	갱신 수	학습 응답 토큰
단독 C1	5,952	744	1,651,827
단독 C2	3,664	458	585,979
단독 C3	1,608	201	169,261
중앙집중	11,224	1,403	2,407,067

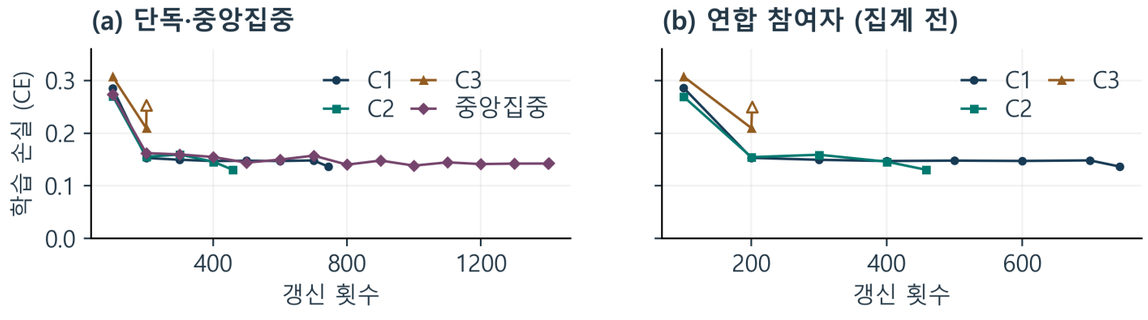
• 각 참여자는 자기 자료로 1 epoch 학습. 같은 자료 풀·초기 어댑터를 사용했고, 연합의 갱신 횟수는 위 단독모델과 같다(합계 1,403회).
• 중앙집중은 한 모델이 전체 자료를 학습한다. 연합은 세 모델이 따로 학습한 뒤 어댑터를 합친다.

근거 2 | 전체 자료 중 실제 학습에 쓴 부분

참여자	전체 학습 쌍	결함 / 정상	선택 학습 쌍
C1 · ST	23,806	17,078 / 6,728	5,952
C2 · ST	14,629	4,686 / 9,943	3,664
C3 · AL	6,410	3,016 / 3,394	1,608

표의 범위: 결함/정상은 전체 유효 학습 쌍의 구성, ST·AL은 자료에 기록된 재질이다.
미확인: 학습 표본 변경의 효과. 선택 자료의 결함별 분포는 A6-1 참조.

손실 감소가 검출 성능의 수렴인가?



응답 토큰의 교차엔트로피 손실을 학습 800쌍씩 묶어 토큰 수로 가중 평균했다. C3의 마지막 8쌍은 빈 점이다. 검증 영상의 검출 성능 추이가 아니므로 이 곡선만으로 검출 성능의 수렴을 판단할 수 없다.

근거 3 | 두 집계식은 일반적으로 다름

$$\Delta W_{\text{sep}} = \frac{\alpha}{r}\left(\sum_{k=1}^{3} p_k B_k\right)\left(\sum_{k=1}^{3} p_k A_k\right) \quad \text{본 실험}$$

$$\Delta W_{\text{prod}} = \sum_{k=1}^{3} p_k \frac{\alpha}{r} B_k A_k \quad \text{비교식}$$

• $A_k \cdot B_k$: 참여자 k의 LoRA 행렬(k=1, 2, 3). α/r = 32/16 = 2.
• 본 실험 ΔW_{sep}: A·B를 각각 평균한 뒤 곱한 변화량.
• 비교식 ΔW_{prod}: BA를 먼저 계산한 뒤 평균한 변화량. 두 식은 일반적으로 다르다.

$$p_k = \frac{N_k}{\sum_{j=1}^{3} N_j}, \qquad \sum_{k=1}^{3} p_k = 1$$

N_k는 손실 계산에 포함된 응답 토큰 수다. 토큰 비율은 집계 가중치이며 기여도나 보상 비율이 아니다.

집계 진단의 기존 보고값	관측
단독 어댑터로 계산한 두 집계식의 층별 상대 차	중앙값 0.040 최대 0.144
참여자 갱신량 사이의 상대 거리	중앙값 0.88–1.06

계산 범위: 11-03 분석·11-04 해석 정정값. 실제 연합 실행과 학습 순서가 다른 단독 어댑터를 사용했다.
해석 한계: 출력 성능을 비교하지 않아 C1 하락의 원인인지 알 수 없다. 상대 거리만으로 갱신 방향의 직교성을 판단할 수도 없다.

후속 검증 | 반복 학습·원인·완화 효과

• 단일 통신으로 연합모델을 만드는 one-shot FL 연구[14]는 존재한다. Guha 등의 앙상블·지식 집계와 이번 LoRA A·B 평균은 다른 구현이다.
• 참여자 학습 1 epoch와 집계 1라운드는 별개다. 집계 모델의 재배포·추가 학습을 반복한 효과는 미검증이다(A6-2).
• C1 하락만으로 무임승차[15]·데이터 오염[16]을 추론할 수 없다. 개인화·재가중의 개선 효과도 아직 비교하지 않았다.

학습에 쓴 사례 80건을 다시 맞힌 암기 시험(80/80)은 구현 점검이다. 처음 보는 영상에서의 검출 성과가 아니다.

출처: 학습 원장·연합 실행·손실 기록, 학습 쌍 구성표, 집계 진단 정정판. 독립 재실행 없이 보고값 인용.

A2 누가 이득을 얻고, 참여 비용은 얼마나 드는가?

C2·C3는 기공을 추가로 찾았지만 오탐도 늘었다. 학습 시간·교환량만으로 실제 운영에서의 순이득을 판단할 수는 없다.

근거 1 | 새로 찾은 결함과 새로 놓친 결함

단독→연합	둘 다 검출	단독만 검출	연합만 검출	둘 다 누락
C1	62	53	36	1,772
C2	25	18	73	1,807
C3	24	10	74	1,815

분석 범위: 정답 상자 1,923개, 사후 분석, 표본 가중치 미적용.
대응 방식: 종류 일치·IoU≥0.5에서 순차적으로 짝지음. 가능한 대응 수를 최대화하는 정식 채점과 다르다.

검출 보완은 주로 기공에서 나타남

참여자	기공: 단독만 / 연합만	그 밖의 변화
C1	46 / 35	균열 2개·융합불량 5개 새로 누락 융합불량 1개 새로 검출
C2	18 / 71	융합불량 2개 새로 검출
C3	9 / 72	슬래그 1개 새로 누락 융합불량 2개 새로 검출

오탐 상자(FP)	단독 C1	단독 C2	단독 C3	연합
비가중 건수	1,955	2,040	2,167	2,454

관측: 일부 기공을 추가로 검출했지만 오탐도 증가.
미평가: 원인 진단 능력과 실제 검사 업무의 감소.

성능이 높은 C1 모델을 공유하면 되는가

- 하나의 연합모델을 단독모델 세 개와 각각 비교했다. 독립된 연합 실험을 세 번 반복한 결과는 아니다.
- 공통 평가에서 C1의 Macro-F1이 연합모델보다 높았다. 가장 좋은 단독모델을 공유하는 방법보다 연합이 유리하다는 근거는 없다.
- AL 영상만의 결과를 C3의 실제 검사 성능으로 볼 수 없다. 재표집 2,000회 중 유효한 비교가 914회여서 등록 판정에 필요한 횟수를 충족하지 못했다.

근거 2 | 학습 시간과 교환 파일 크기

참여자	단독 학습(h)	연합 참여자 학습(h)
C1	6.7	6.9
C2	3.8	4.1
C3	1.7	1.7

- 기록값: 중앙집중 12.8시간, 연합 참여자의 학습 시간 합 12.7시간.
- 집계 범위: 단독·중앙집중은 실행 원장, 연합은 마지막 학습 기록으로 서로 다르다.
- 해석: 전체 완료 시간이나 과금 GPU 시간이 아니므로 비용 절감으로 환산할 수 없다.

어댑터 교환량	범위
참여자 업로드 약 129.9 MB	129,859,584 byte
왕복 약 259.7 MB	같은 크기 파일의 다운로드를 가정 MB = 1,000,000 byte; 실측 전송량 아님

후속 검증 | RQ2에서 아직 답하지 못한 부분

RQ2의 축	현재 답 / 필요한 검증
성능 편익	같은 영상의 단독·연합 점수는 비교함. 참여자 자체 검사자료의 성능과 실제 오류 비용은 미평가.
계산·통신·운용 비용	학습 시간·어댑터 크기 기록. 서버·대기·인력·추론비를 포함한 순이득은 미평가.
연합모델 기여·보상	토큰 비율은 집계 가중치. 참여자 제외·조합별 성능과 보상 규칙을 평가하지 않음.
C1의 참여 유인	현재 모델 교체만으로 검출 이득이 없음. 개인화·보상 등의 유인은 후속 설계 대상.

필요 자료: 같은 실행의 연합 참여자 어댑터와 적절한 조합 평가.
기여 분석의 한계: 학습 순서가 다른 단독 어댑터로 대체하거나 일부 조합만 평가해서는 모든 조합에 기반한 Shapley 기여도를 얻을 수 없다.

범위 이력: 비용·기여·보상을 포함한 RQ2 확장은 결과 확인 후 추가됐다. 질문의 넓은 범위를 유지하되, 사후 보강과 현재의 부분 답을 구별한다.

A3-1 응답 실패를 불리하게 처리해도 결과가 유지되는가?

실패 응답에 벌점을 더해도 C2·C3 상승과 C1 하락은 유지됐다. 다만 세 단독모델의 평균 대비 차이는 반전됐다.

근거 1 | 실패 응답도 평가에 포함

모델	실패 / 1,059	실패율	길이 한도 도달
단독 C1	12	1.13%	12
단독 C2	301	28.42%	301
단독 C3	143	13.50%	149
중앙집중	16	1.51%	15
연합	37	3.49%	38

중앙집중의 실패는 잘림 15건과 JSON 해석 실패 1건이다. 나머지 모델의 실패는 잘림으로 기록됐다. 1,280토큰 한도에 도달해도 응답을 읽을 수 있는 경우가 있어 두 열의 건수는 다르다. 표는 가중치 없는 영상 수다.

근거 2 | 출력은 고정하고 실패 처리만 비교

주 분석	**실패한 응답을 검출 상자 0개로 처리. 정답 결함은 누락(FN)이 되며, 결함이 없는 영상에서는 오탐(FP)이 생기지 않음.**
실패 벌점 민감도	실패한 영상마다 네 결함 종류에 오탐(FP)을 각각 1개 추가. 같은 응답에 채점 규칙만 달리 적용한 비교.

모델	주 분석 Macro-F1	실패 벌점 Macro-F1
단독 C1	0.0493	0.0461
단독 C2	0.0058	0.0053
단독 C3	0.0061	0.0054
중앙집중	0.0993	0.0912
연합	0.0213	0.0187

벌점을 더하면 연합-단독 평균의 차이는 +0.0009에서 -0.0002로 바뀐다. C2·C3 상승과 C1 하락은 유지된다. 응답 잘림을 고쳤을 때 얼마나 개선될지는 이 비교로 알 수 없다.

검출·오탐·누락은 A3-3에서 비교

모델별 전체 집계와 연합모델의 결함별 집계는 A3-3(5쪽)에 모았다. 낮은 절대 성능만으로 최적화 미수렴을 확정할 수는 없다.

생성한 설명이 응답 규칙을 지켰는가

모델	응답 규칙 위반 탐지율*	판정 유보 문구 충족률†	완결 설명문(건)
단독 C1	24.0% (n=1047)	89.9% (n=588)	1047
단독 C2	15.9% (n=758)	73.8% (n=329)	758
단독 C3	0.7% (n=916)	5.4% (n=468)	910
중앙집중	23.5% (n=1043)	89.6% (n=584)	1043
연합	25.2% (n=1022)	90.7% (n=563)	1021

* 이 연구의 응답 규칙에서 허용하지 않은 주장(예: 관련 없는 조항 인용)을 자동으로 탐지한 비율이다. 표본 가중치를 적용했으며 검사기 자체의 오탐이 남아 있다. 연합 25.2%의 대부분은 조항 관련 탐지(25.1%)다. 설명문을 세는 지표이므로 인용을 세는 A3-2 비율과 더하지 않는다.

† 정답 결함에 필요한 판정 유보 문구를 포함했는지 검사했다. 예측 결함을 기준으로 검사한 비율과 구별한다. n은 실제 검사 대상 응답 수이며 가중 분모나 전체 평가 영상 수가 아니다.

연합의 판정 유보 문구 충족률은 가중 합계 6,310.24/6,959.59 = 90.7%다(실제 검사 대상 563건). 위반 탐지가 적어도 설명 자체를 생략했을 수 있다. 이 비율은 전문가가 검증한 설명 정확도가 아니다.

출처: 정식 평가 결과. 모델마다 설명문 검사 대상 수가 다르므로 비율과 함께 완결된 설명문 수도 제시했다.

A3-2 진단이라면서 왜 결함과 기준만 설명하는가?

이번 실험은 결함 검출과 규정 인용을 평가했다. 발생 원인·보수 방법·합부 판정까지 다루는 진단 능력은 검증하지 못했다.

연구용 기준표와 일치한 조항, 관련 없는 인용

모델	내부 일치율	인용 정밀도	비관련 인용률
단독 C1	69.6%	61.1%	38.9%
단독 C2	27.6%	56.5%	43.5%
단독 C3	0.0%	미정의	미정의
중앙집중	68.9%	61.5%	38.5%
연합	64.2%	58.6%	41.4%
메타데이터 기준모델	98.6%	92.6%	7.4%

연합: 일치 4,501.57 / 정답 7,014.16 = 64.2%. 인용 정밀도 4,501.57 / 인용 7,678.60 = 58.6%. 비관련 인용 3,177.03 / 7,678.60 = 41.4%. 설계가중 합계이며 원시 정답 (영상, 코드) 쌍은 557개, 인용 단위는 620개다.

인용 조항은 영상별 목록으로 평가했으며 개별 검출 상자와의 연결은 검증하지 않았다. C3는 인용이 없어 두 인용 비율을 계산할 수 없다. 기준모델에는 재질 정보를 주었지만 VLM 지시문에는 주지 않았다.

검출 성공과 설명 오류가 함께 나타난 사례 A

본문 그림 4의 사례 A / 중앙집중 · 영상 14487530
균열 2개 검출 성공. 자료의 명목 재질은 AL이나 응답은 ST용 KRA27-3D를 인용했다.

모델 응답 원문
"방사선투과 영상에서 균열(ISO 6520-1 코드 100) 2개가 관찰된다. 균열에 현 허용치 표에서 대응되는 조항은 KRA27-3D 이다. 이 조항의 기준은 다음과 같다. 모든 두께: 크기와 무관하게 허용하지 않는다. 이 기준은 품질등급이 지정되지 않은 경우의 기준이고, 이 자료는 등급 지정 여부를 확인하지 않는다. 크기와 무관한 기준은 치수 정보가 필요 없지만, 이 자료는 그 기준의 실제 적용 전제를 확인하지 않고 판정 축을 조항 검색과 기준 서술로 한정해 합부 판정을 싣지 않는다."

연구용 허용치 표는 ST 범위이며 AL 적용을 검증하지 않았다. 기준표의 전문가 이중 검증과 실제 규정 적용 검증은 완료되지 않았다.

원인·보수 방법을 다루지 못한 이유

학습 설명문은 결함 라벨과 연구용 기준표로 구성했다. 원인·보수 방법의 전문가 정답은 구축하지 않았고 관련 정확성도 평가하지 않았다. 실제 진단으로 확장하려면 전문가 소견·보수 조치 정답과 별도 평가가 필요하다.

B: 단독모델 셋이 놓친 기공을 연합모델이 검출

영상 14535735	중앙집중	연합	C1	C2	C3
TP / FP / FN	0 / 7 / 1	1 / 0 / 0	0 / 1 / 1	0 / 0 / 1	0 / 1 / 1

본문 그림 4의 사례 B: 상자 없는 영상과 상자 있는 영상은 같은 확대 영역. 연합의 대응 IoU는 0.811. 단독 3종이 놓친 한 사례를 보여 주며, 희미한 영상에 대한 강건성 시험은 아니다.

모델 응답 원문
"방사선투과 영상에서 기공(ISO 6520-1 코드 2011) 1개가 관찰된다. 기공에 현 허용치 표에서 대응되는 조항은 KRA27-T15 이다. 이 조항의 측정량은 최대결함크기이고, 기준은 다음과 같다. 두께 10 mm 이하: 4 mm 이하 / 두께 10 mm 초과 25 mm 이하: 5 mm 이하 / 두께 25 mm 초과 50 mm 이하: 모재 두께의 0.2 배 이하 / 두께 50 mm 초과 100 mm 이하: 10 mm 이하. 이 조항에는 기계 표현으로 옮기지 못한 단서가 있어 위 기준만으로 합부를 결정하지 않는다. 종별을 가리기 어려우면 두 종별의 기준으로 각각 평가한다는 조건이 있고, 이 자료는 그 구별을 확인하지 않는다. 이 기준은 품질등급이 지정되지 않은 경우의 기준이고, 이 자료는 등급 지정 여부를 확인하지 않는다. 모재 두께와 화소당 실치수 정보가 없어 치수 기준의 합부 판정은 내리지 않는다."

D: 정답에 없는 기공에 허용 기준까지 설명

본문 그림 4의 사례 D / 연합 · 결함 라벨이 없는 영상 14484973
모델 응답 발췌: "방사선투과 영상에서 기공(ISO 6520-1 코드 2011) 7개가 관찰된다. 기공에 현 허용치 표에서 대응되는 조항은 KRA27-T15 이다."
정답 결함은 없지만 기공 7개와 관련 조항을 출력했다.

학습 정답은 모두 합부 판정을 비워 두었다(verdict=null). 따라서 '판정불가' 출력만으로 모델이 위험을 알아보고 판단을 유보했다고 볼 수 없다.

사례는 결과 확인 후 고른 성공 3건+연합 실패 1건. C의 기공 설명은 B와 동일 문구이므로 반복 수록하지 않았다. 상자는 원본 영상과 저장 좌표로 표시했으며 응답을 정답처럼 고쳐 쓰지 않았다.

본문에서 뺀 코드의 출처와 역할

코드는 원문과 연구용 기준표를 연결한 식별자다.
• KRA27-3D: 한국선급(2025) 제2편 부록 2-7의 (d), 제3종(균열) 기준.
• KRA27-T15: 같은 부록의 표 15, 제1종(기공)의 크기 기준.
원문 응답과 인용 채점을 추적하기 위해 부록에 보존한다. 코드의 일치가 실제 규정 적용이나 진단 정확성을 뜻하지는 않는다.

A3-3 얼마나 찾았고, 얼마나 잘못 찾거나 놓쳤는가?

연합모델은 정답 결함 1,923개 중 98개를 검출하고 1,825개를 놓쳤다. 오탐은 2,454개였다.

전체 평가 1,059장 | 모델별 상자 집계

모델	검출(TP)	오탐(FP)	누락(FN)
단독 C1	115	1,955	1,808
단독 C2	43	2,040	1,880
단독 C3	34	2,167	1,889
중앙집중	254	1,733	1,669
연합	98	2,454	1,825

표 A3-3a. 같은 영상 1,059장에서 센 비가중 상자 수. 정상 영상의 오탐과 실패 응답에 따른 누락을 포함한다.

연합으로 바꿨을 때의 건수 차이

연합 - 단독	검출 차이	오탐 차이	누락 차이
단독 C1	-17	+499	+17
단독 C2	+55	+414	-55
단독 C3	+64	+287	-64

C2·C3보다 검출은 늘었지만 오탐도 늘었다. C1과 비교하면 검출은 줄고 오탐은 늘었다. 결함을 더 찾았다는 사실만으로 검사 부담이 줄었다고 판단할 수 없다.

표 A3-3b. 전체 건수의 차이이며, 새로 찾은 결함 수는 아니다. 같은 결함의 검출·누락 전환은 A2의 대응 분석에서 별도로 확인한다.

출처: 정식 평가 저장 결과(비가중 집계). 저장된 건수의 합계와 차이만 계산했으며 새 추론·채점은 수행하지 않았다.

연합모델 | 결함별 검출·오탐·누락

결함	정답	검출(TP)	오탐(FP)	누락(FN)
균열	58	0	11	58
기공	1,516	96	2,427	1,420
슬래그	262	0	0	262
융합불량	87	2	16	85
합계	1,923	98	2,454	1,825

표 A3-3c. 검출 98개 중 기공 96개·융합불량 2개. 균열·슬래그는 검출하지 못했다. 오탐의 대부분도 기공이었다.

집계 단위와 판정 기준

- 영상 수가 아닌 결함 상자 수. 한 영상에 여러 결함·오탐이 있을 수 있다.
- 검출 성공: 결함 종류 일치, IoU≥0.5에서 일대일 대응.
- 실패 응답: 예측 상자 0개로 처리하며 정답 결함은 누락에 포함.
- 표는 주 분석의 비가중 건수. 본문 Macro-F1은 설계가중을 적용하므로 이 합계에서 직접 계산한 값과 다르다.

혼동행렬로 표현할 수 있는 범위

저장 결과는 종류별 TP·FP·FN 집계다. 배경 영역의 정상 판정(TN)은 정의·집계하지 않았고, 어떤 결함을 다른 종류로 바꿔 예측했는지의 교차 집계는 이 세 값만으로 복원할 수 없다. 따라서 검출 평가에 맞는 건수 표로 제시했다.

현재 자료로 현장 허용 오류 수준의 충족을 주장할 수 없다. 운영 편익을 평가하려면 누락·오탐의 실제 비용과 재검사 시간을 함께 측정해야 한다.

A4-1 0.0213은 무엇의 점수이며, 어디까지 해석할 수 있는가?

0.0213은 연합모델의 결함 검출 Macro-F1이다. 4종 결함의 종류·위치를 함께 평가한 값으로, 설명이나 진단 정확도는 포함하지 않는다.

• Macro-F1: 균열·기공·슬래그·융합불량의 F1을 동일 비중으로 평균. 종류별 F1에는 설계가중 TP·FP·FN을 사용.
• 검출 성공: 결함 종류 일치 + IoU≥0.5의 일대일 대응.
• 단독 평균: C1·C2·C3의 Macro-F1을 산술평균한 값.

근거 1 | 8개 층·101개 묶음의 표본 변동

재질 | 묶음 내 영상당 평균 결함 수 구간	모집단 G_h	표본 n_h	설계가중 G_h/n_h
AL | 0	81	7	11.571
AL | 1	40	3	13.333
AL | 2-3	60	5	12.000
AL | 4+	9	2	4.500
ST | 0	400	32	12.500
ST | 1	102	8	12.750
ST | 2-3	340	27	12.593
ST | 4+	213	17	12.529

• 평가 범위: 미리 고정한 12,461장 중 1,059장.
• 표 기호: h는 재질·평균 결함 수로 나눈 층, G_h는 전체 묶음 수, n_h는 선택한 묶음 수.
• 95% 구간: 층별 묶음 재추출 2,000개에서 같은 모델들을 비교. 표본 가중치와 중복 추출 횟수를 반영했다.

포함한 변동: 평가 표본의 재추출. 재학습 변동은 포함하지 않는다.
남은 검증: 구간의 실제 포함률, 작은 층의 분산 보정, 여러 비교를 동시에 판단할 때의 오류.

후속 검증 | 영상 분리와 독립 평가

• 영상 ID·묶음 ID의 분할 간 교집합은 0으로 기록됐다. 묶음이 실제 동일 용접부·촬영 작업 단위를 충분히 분리하는지는 검증되지 않았다.
• 기존 근사 중복 감사는 학습·검증과 평가 사이 최소 33쌍의 매우 유사한 영상을 기록했다. 해당 감사 이후 독립 재검증은 완료되지 않았다.
• 제외 민감도·새 촬영 환경의 독립 평가가 없으므로 ID 비중복만으로 평가 독립성 문제가 해결됐다고 볼 수 없다.

근거 2 | 평가 규칙과 현장 합격선은 다름

$$R=\frac{F-L_{\text{avg}}}{C-L_{\text{avg}}},\qquad D=C-L_{\text{avg}}$$

R은 단독 평균과 중앙집중 간 성능 격차 중 연합이 메운 비율이다. F는 연합, C는 중앙집중, L_{avg}는 단독모델 3개의 평균 Macro-F1이다.

기준	의미와 현재 상태
상자 대응 종류 일치 + IoU≥0.5	검출 채점의 대응 기준. 현장 검사 합격선이나 수리 허용 기준이 아님.
등록 회복률 채택 규칙	95% 구간 반폭≤0.25·계산 제외/미정의 비율≤0.10·시드 간 안정성 조건. 현재는 학습 시드 1개로 채택 여부 미판정.
등록 대조선 초과 조건	중앙집중·연합이 대조선을 넘는 조건과 양의 차이 구간 하한을 충족하지 못함.
추가 전량 평가 발동	D는 중앙집중-단독 평균의 차이. D=0.0789<0.115로 조건에 해당하나 이번 제출에서는 미실행. 결과는 표본 1,059장에 한정.
현장 실용 기준	허용 누락·오탐·시간·비용과 최소 개선 폭 미설정. 실제 운영자와 정할 후속 기준.

단독 평균 0.0204는 세 모델 점수의 평균이며 하나의 모델 성능이 아니다. 연합 0.0213과 중앙집중 0.0993은 각 모델의 점수다.
'근접'은 관측값 비교이며 동등성·비열등성·현장 합격을 뜻하지 않는다. 중앙집중과의 차이 0.0780이 실용적으로 허용되는지도 미설정.

후속 검증 | 실제 사업장의 운영 조건

실험 조건: 한 장비의 모사 참여자 세 곳. 참여자별 자료로 학습했으나 밝기 정합에는 학습·검증 풀의 공통 통계를 사용했다.
미평가: 실제 사업장의 독립 운영, 통계 공유 절차, 프라이버시 보호·공격 저항성.

유효한 결함 상자 좌표가 없는 학습·검증 쌍을 각 1건 제외했다. 학습 영상 분할 44,846장과 유효 학습 쌍 44,845건을 혼용하지 않는다. 선택된 실제 학습은 11,224쌍이다.

학습 자료를 늘리는 일과 현재 모델을 12,461장 전체에서 평가하는 일은 다르다. 후자를 수행해도 유사 영상 문제가 자동으로 해결되지는 않는다.

A4-2 결과를 본 뒤 무엇을 바꿨는가?

등록은 학습 완료 후·평가 생성 전에 진행했다. 정식 채점 전 미리 보기 2회의 노출 범위와 이후 변경을 구분했다. 시각은 KST.

시점	사건·노출 범위	변경·고정 및 근거
10-01	유사 영상 제한을 알고 현행 분할 유지	탐색적 비교로 범위 제한. 의사결정로그 1120–1133.
10-31–11-01	학습량 1/4·누적 8·생성 배치 1 선택	2차 결과 확인 전. 기존 1/8 시작은 중단. 로그 1813·1957.
11-01–11-02	학습과 연합 실행 재시도	인프라 실패 후 첫 정상 완료를 채택하는 규칙. 성능 최고값을 고른 것이 아님. 로그 1982.
11-02 14:08:43	2차 등록 접수; 학습 완료 후·평가 생성 전	1/4·누적 8·생성 한도 1,280·채점 판6·평가 1,059장. 등록 영수증 a5f6220e.
11-02 14:17–14:48	평가 생성 준비 검사 실패·수정	실행 식별정보 추출·입력 토큰 확인 옵션·기록 정보 수정. 평가 점수 확인 전. 로그 1996–1997.
11-03 13:08	미리 보기 1: 중앙집중·연합·C1	C2·C3 미회수. 대조선 미달 확인 및 시드 2 조건 불충족 판단. 로그 2067·부분 보고서.
11-03 오후	전량 학습 준비 후 보류; 집계 진단	설정의 학습 비율을 100%로 바꿨으나 등록 사본은 25% 유지. 실제 전량 학습 결과는 없음.
11-03 23:05 → 23:06	미리 보기 2: 다섯 모델 → 정식 호출 1회	전체 미리 보기와 정식 결과의 보고 내용이 동일. 채점 원장 2행 중 1행은 이전 1차 실험.
11-04–11-05	검산·미리 보기 횟수 정정·전량 평가 미이행 확인	11-05 사용자 결정으로 이번 제출 전량 평가 미실행. 마감 뒤 실행도 확약하지 않음.
11-07	사후 근거 정리와 RQ2 범위 복원	검출 변화·자원·기여/보상의 부분 답 구분. 정식 결과를 바꾸는 재채점은 하지 않음.

등록한 내용과 사후에 추가한 분석

등록 내용	등록 전 코드의 세부 선택	사후 탐색·문서 보강
평가 목록·채점 규칙·실패 벌점 민감도. 등록은 학습 시작 전이 아니라 평가 생성 전.	층 안 묶음 복원추출·분산 보정 없음. 등록 칸은 없으나 10월 코드에 이미 존재.	집계 수치 진단·사례 선정·검출 얻음/잃음·비용/기여를 포함한 RQ2 확장.

남은 검증 | 평가 독립성

등록 이후 정식 채점까지 추적된 채점 경로의 코드 변경은 없었으나, 이것만으로 임시·비추적 변경이 없었다거나 평가 독립성이 확보됐다고 증명하지는 않는다. 저장 보고서는 내용의 증거이며 미리 보기 시각은 당시 로그의 기록이다. 독립 검산은 수치 일치를 확인할 뿐 결과 노출을 되돌리지 않는다.

기록 근거: 등록 main-20261102-1, scoring_ledger 2행, 부분 미리 보기 1dac258a…, 전체 미리 보기 e448ca93…, 정식 산출 2f8ff747…. 11-07 정정 시간표와 원장·커밋의 대조 범위에서 요약.

A5 검출기 대신 VLM을 쓴 이유와 확인한 가치는 무엇인가?

검출과 설명 생성을 공동학습하는 방법을 탐색했다. 전용 검출기에 규칙 설명을 붙이는 방식보다 유용한지는 후속 비교가 필요하다.

근거 1 | 선행연구와 이번 연구의 범위

연구 축	관련 연구	이번 연구의 범위·차이
검출·설명 결합	WeldLLM ICCSN 2025[2] WeldLLM IEEE TII 2026[3]	검출과 보고·진단 추론을 연결한 선행연구. 두 출판물을 구별해 인용. 이번 출력 정답은 라벨+연구용 기준표이며 전문가 원인·조치 정답이 아님.
제조 현장의 공동학습	FedAvg[4], 제조 품질검사 FL[5] 이질성 대응 FedProx[11]·SCAFFOLD[12]	모사 참여자 3곳·단일 집계. 실제 사업장 분산 운영이나 이질성 완화 기법의 비교를 수행하지 않음.
효율적 미세조정·집계	LoRA[6]·QLoRA[7] FLoRA[8]·FFA-LoRA[13]	Qwen3.5-4B의 양자화 기본 가중치 고정, LoRA 학습 후 A·B 각각 토큰 가중 평균. 선행 집계 기법과의 우열은 비교하지 않음.
불균형·자료 수준 접근	용접 결함 분류[1] 강판 결함 증강[9]·자료 수준 FL[10]	불균형과 자료 구성이 중요한 배경. 기존 과제의 F1·Dice·AP 숫자를 현재 4종 검출 Macro-F1과 직접 비교하지 않음.

후속 검증 | 검출기+규칙 설명과의 대조

선택 동기: 결함 종류·위치와 관련 기준을 한 응답으로 제공.
확인한 것: 실제 출력과 연구용 기준표와의 내부 일치.
남은 비교: 전용 검출기+규칙 설명보다 유용한가?

빠진 대조	분리해서 확인할 효과
미세조정 전 Qwen	미세조정 자체의 이득과 응답 형식 학습의 영향
영상 제거·교란	영상 화소가 검출·설명에 기여한 정도
동일 조건 검출기+규칙 설명	검출 성능·설명 정확성·추론 비용에서 VLM의 추가 가치
전문가 원인·조치 평가	규칙표 재서술을 넘어 실제 진단에 제공하는 가치

위 대조는 미실행이다. 동일 평가 자료의 새 추론·채점과 전문가 정답 구축이 필요하다.

근거 2 | 현재 대조군으로 판단할 수 있는 범위

- 입력: 영상 번호 구간 등 메타데이터와 결함 라벨의 통계. 영상 화소는 읽지 않는다.
- 자료량: 기준모델 49,847장, Qwen 학습 11,224쌍.
- 비교 범위: 같은 입력·학습량의 대조도, 성능 상한선도 아니다. 점수가 낮다는 이유만으로 Qwen의 영상 미사용을 단정할 수 없다.

기존 YOLO11s 사전실험	이번 Qwen 비교
결함 통합 1클래스 AP	결함 4종 Macro-F1
평가 12,461장·정답 상자 22,549개	공통 표본 1,059장
탐욕 VOC 대응·IoU≥0.5	종류·위치 동시 대응
PR 집계 confidence≥0.01	설계가중·출력 실패 포함

별도 YOLO·열지도 결과를 Qwen 연합 참여의 편익으로 합치지 않는다. 같은 평가 자료·학습 예산·출력 요구를 맞춘 대조가 필요하다.

판단에 필요한 다음 근거: 같은 평가 자료·학습 예산·출력 요구의 대조, 참여자별 실제 검사 성능과 오류 비용. 이번 공통 평가에서 관측한 C2·C3 개선과 C1 하락의 현장 재현 여부는 독립 평가로 확인해야 한다.

A6-1 참여자마다 어떤 학습자료가 있었는가?

C3는 학습 쌍이 가장 적지만 슬래그 라벨 영상 비율은 가장 높다. 자료의 차이가 성능 기여를 보장하지는 않는다.

전체 유효 학습 풀과 실제 선택 학습자료

구분·참여자	전체 (쌍)	결함 영상 (장)	정상 영상 (장)	균열 영상 / 상자	기공 영상 / 상자	슬래그 영상 / 상자	융합불량 영상 / 상자
전체 C1	23,806	17,078	6,728	1,445 / 3,039	13,531 / 47,509	73 / 158	2,117 / 2,908
전체 C2	14,629	4,686	9,943	28 / 44	4,052 / 15,808	628 / 1,357	14 / 46
전체 C3	6,410	3,016	3,394	264 / 463	1,808 / 4,637	738 / 1,478	234 / 309
선택 C1	5,952	4,279	1,673	364 / 804	3,404 / 11,791	19 / 49	512 / 678
선택 C2	3,664	1,153	2,511	6 / 10	990 / 3,941	159 / 316	5 / 37
선택 C3	1,608	738	870	69 / 120	436 / 1,054	188 / 365	55 / 72

단위: 유효 영상–응답 1쌍은 영상 1장에 해당한다. 결함 영상은 유효 결함 상자가 1개 이상인 영상, 정상 영상은 해당 라벨이 없는 영상이다. 정상 라벨이 실제 무결함을 보증하지는 않는다. 결함별 영상 수는 중복 집계되므로 네 종류를 더해 결함 영상 수로 쓰지 않는다. 상자 수는 한 영상의 여러 결함을 각각 센다.

실제 선택 학습자료의 비율

참여자	학습 쌍 비중	결함 영상 비율	슬래그 영상 비율
C1	53.03%	71.89%	0.32%
C2	32.64%	31.47%	4.34%
C3	14.33%	45.90%	11.69%

분모: 학습 쌍 비중은 전체 선택 11,224쌍, 두 영상 비율은 각 참여자의 선택 학습 쌍 수다. 상자 비율이나 평가 표본의 설계가중 비율과 구별한다.

C1·C2의 명목 재질은 ST(강재), C3는 AL(알루미늄)이다. C3는 작은 자료로 다른 재질과 결함 구성을 제공한다. 용접 구조 자체의 독특함이나 현장 대표성은 이 재질·라벨 집계만으로 확인할 수 없다.

표본 선택과 분포의 해석

전체 유효 학습 풀은 44,845쌍이다. 영상 분할의 44,846장 중 유효 결함 좌표가 없는 1건을 제외한 수다. 참여자별 약 1/4을 고정 시드로 선택하고 누적 학습 단위에 맞춰 11,224쌍을 사용했다.

분포표는 학습 결과 확인 후 보강한 기술 통계다. 저장 학습자료의 선택 규칙으로 목록을 복원하고 세 완료 모델의 학습 목록 지문·행 수·응답 토큰 합과 일치함을 확인했다. 새 학습·추론·정식 재채점은 수행하지 않았다.

C3에 슬래그 자료가 있어도 C3만의 정보라고 단정할 수 없다. 선택 학습자료에는 C1 49개, C2 316개, C3 365개의 슬래그 상자가 있다. 자료량·재질·결함 빈도와 집계 방식의 영향을 분리한 비교가 필요하다.

출처: pairs_main_v2의 학습 라벨, 완료 학습 메타데이터와 행별 토큰 표. 분할·선택 및 집계 단위의 상세 기록은 별도 검토 기록에 보존했다.

A6-2 C3의 기여와 반복 집계는 어떻게 검증할 것인가?

이번 결과는 집계 1회의 비교다. C3가 얻은 편익과 C3가 제공한 기여를 나누고 반복 학습·집계와 자료 확대를 별도로 검증해야 한다.

C3가 얻은 편익과 제공한 기여

공통 평가셋에서 단독 C3를 연합모델로 바꾸면 Macro-F1이 0.0061에서 0.0213으로 높아졌다(차이 +0.0152). 이는 C3 입장에서 모델 교체의 성능 편익이다. C3를 참여시켜 다른 참여자나 연합모델의 성능이 얼마나 좋아졌는지는 이 비교로 알 수 없다.

공통 평가의 슬래그	설계가중 F1	검출 / 오탐 / 누락
단독 C3	0.0068	1 / 31 / 261
중앙집중	0.0000	0 / 0 / 262
연합	0.0000	0 / 0 / 262

본문의 0.007은 단독 C3의 슬래그 F1 0.0068을 세 자리로 반올림한 값이다. 전체 Macro-F1 0.0061과 다르다. 오른쪽은 공통 평가 1,059장 중 슬래그 정답 262개의 비가중 상자 집계이며, AL 영상만의 결과가 아니다.

C3 단독모델도 슬래그 검출은 1개이고 오탐은 31개였다. 중앙집중·연합모델 모두 슬래그를 검출하지 못해 C3의 자료 특성이 슬래그 성능 기여로 이어졌다는 근거는 얻지 못했다. 다만 이 결과만으로 C3의 모든 기여가 0이라고 판단할 수는 없다.

C3의 한계 기여를 확인할 비교

같은 초기 모델·평가 자료·학습 예산 원칙을 고정하고 C1+C2와 C1+C2+C3를 비교한다. 전체 및 재질·결함별 성능, C1·C2의 변화, 누락·오탐을 함께 본다. C3 포함·제외에 따라 바뀌는 자료량과 집계 가중치도 통제하거나 별도 보고해야 한다.

포함·제외 비교는 특정 조합에서의 기여를 평가한다. Shapley 기여도에는 다른 참여자 조합도 필요하다. 토큰 집계 가중치를 기여도·크레딧·보상으로 대체하지 않고, 비용과 보상 규칙을 함께 평가해야 한다.

집계 1회에서 확인하지 못한 순환 구조

이번에는 같은 초기 어댑터에서 참여자들이 각각 학습한 뒤 한 번 집계했다(R=1). 집계한 연합모델을 다시 참여자에게 배포하고 추가 학습·집계를 반복하지 않았다. 따라서 반복 교환에 따른 개선이나 수렴을 검증한 결과로 해석할 수 없다.

후속 비교에서는 연합모델 배포 → 참여자 추가 학습 → 집계를 여러 라운드 수행하며 라운드별 성능과 참여자 간 차이를 기록한다. 라운드가 늘면 총 학습량·통신량도 달라지므로 예산을 맞춘 단독·중앙집중 대조와 복수 시드가 필요하다.

자료 확대와 반복 집계를 구별한 후속 설계

비교 축	확인할 질문
같은 11,224쌍 · 집계 횟수 변경	자료를 고정했을 때 반복 교환이 성능에 미치는 영향은? 총 학습량을 맞춘 대조가 필요.
같은 집계 조건 · 학습 자료 확대	선택 표본을 전체 유효 학습 풀 44,845쌍으로 늘렸을 때의 변화는? 자료량과 학습량을 함께 보고.
C3 포함·제외 및 참여자 조합	C3가 제공한 정보의 추가 이득은? 재질·결함별 성능과 자료량 효과를 분리.
독립 평가 · 실제 운영 조건	결함별 누락·오탐, 시간·계산·통신·운용 비용을 함께 볼 때 참여 편익이 있는가?

현재 모델을 평가 영상 12,461장 전체에서 평가하는 작업은 학습 자료 확대나 반복 집계와 별개다. 위 후속 비교와 전량 평가는 이번 제출에서 수행하지 못했으며, 향후 실행을 완료한 것으로 보고하지 않는다.

R 참고문헌과 질문 찾아보기

본문의 핵심 근거를 확장한 서지 목록. 질문별 추가 근거는 A1–A6에서 찾을 수 있다.

[1] 한민기·김도희·배혜림 (2025). 임곗값 최적화 기반 용접 결함 분류: 클래스 불균형 문제 해소를 중심으로. 대한산업공학회지 51(6), 515–526.

[2] Yin et al. (2025). WeldLLM: A Vision-Language Fusion Framework for Weld Defect Detection and Report Generation. ICCSN, 294–298. DOI:10.1109/ICCSN66511.2025.11172613.

[3] Sun et al. (2026). WeldLLM: A Multimodal Framework for Welding Defect Detection and Automated Diagnostic Reasoning. IEEE TII 22(7), 6478–6487. DOI:10.1109/TII.2026.3678237.

[4] McMahan et al. (2017). Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS, PMLR 54, 1273–1282.

[5] Hegiste, Legler & Ruskowski (2023). Federated Object Detection for Quality Inspection in Shared Production. arXiv:2306.17645v2.

[6] Hu et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685.

[7] Dettmers et al. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. arXiv:2305.14314.

[8] Wang et al. (2024). FLoRA: Federated Fine-Tuning Large Language Models with Heterogeneous Low-Rank Adaptations. arXiv:2409.05976.

[9] 안인범·김성범 (2022). 객체 수준 데이터 증강을 활용한 딥러닝 기반의 강판 표면 결함 검출. 대한산업공학회지 48(4), 327–339. DOI:10.7232/JKIIE.2022.48.4.327.

[10] 배진수·박소연·최지형·김지현·함성일·이보경·강필섭·김성범 (2026). 이상 고객 데이터에 강건한 냉장고 온도 예측용 데이터 수준 연합학습 기법. 대한산업공학회지 52(3), 268–278. DOI:10.7232/JKIIE.2026.52.3.268.

[11] Li, Sahu, Zaheer, Sanjabi, Talwalkar & Smith (2020). Federated Optimization in Heterogeneous Networks. MLSys 2, 429–450.

[12] Karimireddy, Kale, Mohri, Reddi, Stich & Suresh (2020). SCAFFOLD: Stochastic Controlled Averaging for Federated Learning. ICML, PMLR 119, 5132–5143.

[13] Sun, Li, Li & Ding (2024). Improving LoRA in Privacy-preserving Federated Learning. arXiv:2403.12313.

[14] Guha, Talwalkar & Smith (2019). One-Shot Federated Learning. arXiv:1902.11175.

[15] Fraboni et al. (2021). Free-rider Attacks on Model Aggregation in Federated Learning. AISTATS, PMLR 130, 1846–1854.

[16] Tolpegin et al. (2020). Data Poisoning Attacks Against Federated Learning Systems. arXiv:2007.08432.

예상 질문 → 근거 위치

질문	찾아볼 곳	질문	찾아볼 곳
학습량·1라운드·집계식이 적절한가?	A1 · 1쪽	왜 기준만 설명하며 원인·보수 방법은 없는가?	A3-2 · 4쪽
누가 이득을 얻고 C1은 왜 참여하는가?	A2 · 2쪽	0.0213의 의미·신뢰구간·합격선은?	A4-1 · 6쪽
잘림을 제외하거나 채점을 바꾼 것 아닌가?	A3-1 · 3쪽	언제 결과를 봤고 무엇을 바꿨나?	A4-2 · 7쪽
조항 일치의 분모·오류와 실제 문장은?	A3-2 · 4쪽	왜 VLM이며 검출기·기본모델 대조는?	A5 · 8쪽
전체 검출·오탐·누락 건수는?	A3-3 · 5쪽	표의 건수와 Macro-F1은 어떻게 다른가?	A3-3 · 5쪽
참여자별 자료 불균형은?	A6-1 · 9쪽	C3 기여와 반복 집계는 어떻게 검증하나?	A6-2 · 10쪽

본문의 결과 그림은 공통 평가 표본에서의 비교다. 현장 적용성이나 종합 참여 편익을 판단할 때에는 각 Appendix에 표시한 미평가 범위를 함께 확인해야 한다.