데이터 공유 제약 환경에서 용접 결함 진단을 위한 시각언어모델 연합학습 효과 분석

울산정보산업진흥원

조현건[1] · 박상은[2] · 김동훈[3] · 박기수[1]*

[1]UIPA [2]울산과학기술원 노바투스대학원 [3]울산대학교 산업경영공학전공

연구 배경 및 목적

- **현장 문제:** 조선소 검사 영상은 반출 제약이 있어 기관 간 학습자료를 모으기 어렵다. 기관별 자료 부족과 결함 불균형[1]을 보완할 방법으로 연합학습을 검토했다.
- **선행연구:** WeldLLM[2,3]은 결함 검출과 설명 생성을 결합했다. 연합학습[4]을 제조 품질검사에 적용한 연구[5]도 있다. 본 연구는 연합모델이 각 참여자의 검출 성능을 보완하는지 살폈다.
- **연구 목적:** 결함 검출과 검사 기준 설명을 함께 출력하는 VLM에 연합학습을 적용했다. 공통 평가에서 검출 성능과 참여자별 성능 변화를 살핀 예비 연구다.

연구 개요

- **학습·평가:** 영상–응답 11,224쌍으로 Qwen3.5-4B를 학습하고 공통 영상 1,059장에서 균열·기공·슬래그·융합불량의 종류와 위치를 평가했다.
- **비교 구성:** 자료를 나눈 모사 참여자 C1·C2·C3의 단독모델 3개, 자료를 합친 중앙집중모델 1개, 어댑터를 집계한 연합모델 1개를 비교했다.
- **자료 차이:** C1·C2는 강재(ST), C3는 알루미늄(AL) 자료다. C3는 학습 쌍이 가장 적고 슬래그 라벨 영상 비율이 가장 높다.

연구 방법 및 연구 질문

RQ1 연합모델의 검출 성능은 세 단독모델의 평균 및 중앙집중모델과 비교해 어느 수준인가?

RQ2 연합모델로 바꾸면 각 참여자의 성능은 어떻게 달라지는가? 비용·기여·보상까지 고려한 참여 편익은 있는가?

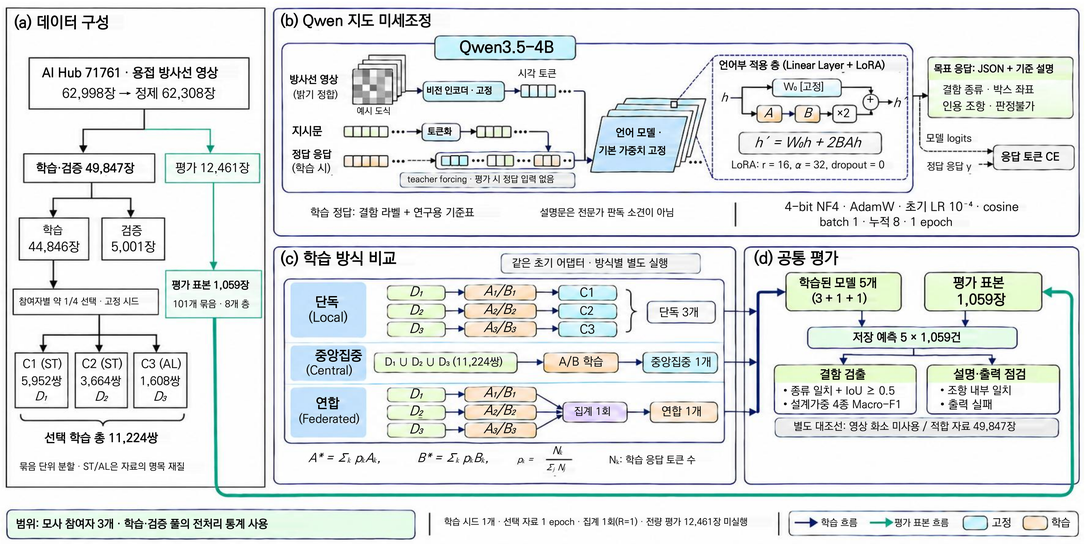
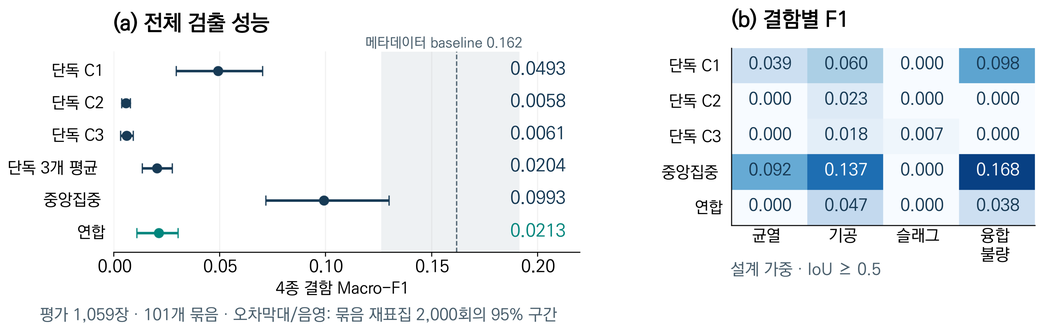


그림 1. (a) 자료 분할·학습 표본 선정 (b) 기본 가중치를 고정한 LoRA 학습 (c) 단독·중앙집중·연합모델 구성 (d) 공통 평가

실험 결과

RQ1 학습 방식별 검출 성능



평가 1,059장 · 101개 묶음 · 오차막대/음영: 묶음 재표집 2,000회의 95% 구간

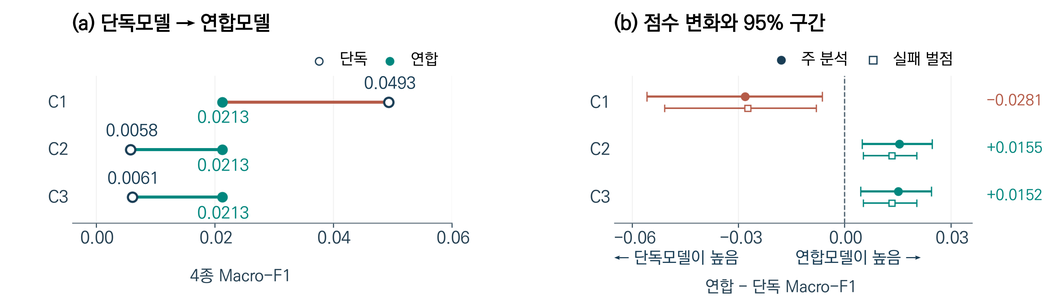
Macro-F1: 결함 종류와 위치를 함께 평가한 4종 결함 F1의 평균

연합 0.0213 · 단독 평균 0.0204 · 중앙집중 0.0993

- 연합모델의 점수는 세 단독모델의 평균과 비슷했지만 중앙집중모델보다 낮았다. 이번 실험에서는 연합학습으로 중앙집중모델 수준의 검출 성능에 도달하지 못했다.
- 잘림·형식 오류로 실패한 응답에 벌점을 더하면 연합–단독 평균의 차이는 +0.0009에서 −0.0002로 바뀐다. 연합의 평균 성능 우위는 실패 처리 방식에 따라 달라졌다.
- 중앙집중은 균열·기공·융합불량에서 연합보다 높은 F1을 보였다. 연합의 단독 평균 대비 개선은 주로 기공에서 나타나 결함별 차이가 컸다.

그림 2. 학습 방식별 Macro-F1과 결함별 F1. 점선: 메타데이터 기반 baseline 모델. 자료량: baseline 적합 49,847장 / Qwen 학습 11,224쌍.

RQ2 참여자별 연합모델 사용 효과



연합모델 사용 시 C2 +0.0155 · C3 +0.0152

C1: −0.0281로 하락, 기존 단독모델이 더 높은 점수

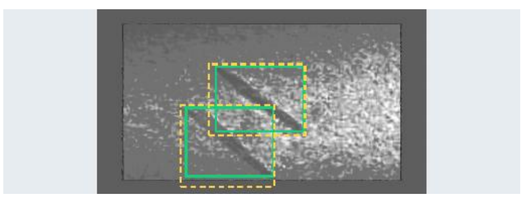
- 점수 차이의 95% 구간은 C2·C3에서 0보다 크고 C1에서 0보다 작았다. 실패 응답에 벌점을 더한 비교에서도 변화 방향이 같았다.
- RQ2에는 공통 평가셋의 검출 성능 변화로 일부만 답했다. 이 변화는 각 참여자가 연합모델에서 얻은 성능 편익이며, 연합모델에 기여한 정도를 뜻하지 않는다.

그림 3. 참여자별 점수 변화(공통 영상 1,059장). 95% 구간: 영상 묶음을 다시 뽑아 계산, 재학습 변동은 제외.

검출 및 생성 응답 사례 분석

결함을 찾았다고 검사 기준 설명도 맞을까?

A 중앙집중 · 균열



검출 2 · 오탐 0 · 누락 0

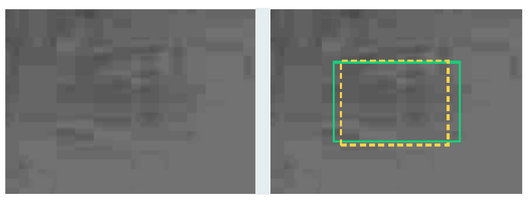
균열 2개 모두 검출 기준 충족(종류 일치·IoU ≥ 0.5)

A 균열 검출은 성공, 적용 기준은 오류

응답 요약: 크기와 무관하게 균열을 허용하지 않음.

검토: 알루미늄 자료에 강재용 검사 기준을 적용.

B 연합 · 단독모델이 놓친 기공 검출



검출 1 · 오탐 0 · 누락 0

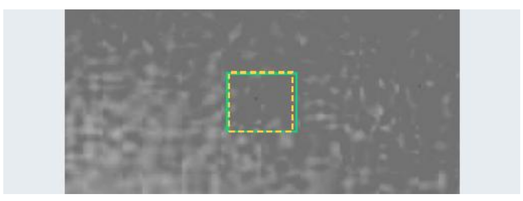
단독 C1·C2·C3는 놓침, 연합만 검출

B 기공 검출과 크기 기준 제시

응답 요약: 두께 ≤10 mm이면 기공 ≤4 mm.

범위: 두께·실제 치수 정보가 없어 합격 여부는 미평가.

C 단독 C1 · 기공



검출 1 · 오탐 0 · 누락 0

단독모델도 정답 기공을 검출한 사례

C 단독모델도 결함과 기준을 함께 출력

응답 요약: B와 같은 기공 크기 기준을 제시.

해석: 단독모델도 결함 검출과 기준 설명을 함께 출력.

D 연합 · 결함 라벨이 없는 영상에서 오탐



검출 0 · 오탐 7 · 누락 0

정답 라벨은 0개인데 기공 7개를 출력

D 정답에 없는 결함의 검사 기준도 설명

응답 요약: 기공 7개와 크기 기준을 제시.

검토: 오탐한 결함을 대상으로 검사 기준을 제시함.

그림 4. 검출 성공(A–C)과 연합모델 오탐(D) 사례. 결과 확인 후 선정. 초록 실선: 정답 / 노랑 점선: 예측 상자. B·C는 확대 영상이며 B 좌우는 같은 영역의 상자 표시 전·후다.

고찰

- 연합모델 채택은 평균 점수와 참여자별 이득·손실을 함께 봐야 한다. C1 단독모델의 점수가 더 높아 이 모델을 공유하는 대안보다 연합학습이 유리하다는 근거는 없다.
- 실패 응답에 벌점을 더하면 연합모델과 단독 평균의 순서가 바뀐다. 실패 처리에 따라 달라지는 작은 평균 차이를 연합학습의 성능 향상으로 해석하기는 어렵다.
- C3는 적은 알루미늄 자료와 상대적으로 높은 슬래그 비중을 가진다. C3 단독모델의 슬래그 F1은 0.007이고 중앙집중·연합모델은 모두 0이다. 자료 특성의 차이가 실제 기여로 이어졌는지는 확인하지 못했다.
- 사례 A에서는 균열을 검출했지만 알루미늄으로 분류된 자료에 강재용 기준을 제시했다. 결함을 맞게 찾은 경우에도 재질과 검사 조건에 맞는 기준을 제시했는지 별도로 검토해야 한다.

평가 범위와 한계: 모사 참여자 3개·학습 시드 1개·집계 1회(R=1)의 비교다. 연합모델을 다시 배포해 학습·집계를 반복하는 효과와 학습 자료 전량 확대 효과는 확인하지 못했다. 유사 영상·정식 채점 전 점수 확인의 영향, C1 하락 원인도 미검증이며 12,461장 전량 평가는 미실행이다. 기관별 실제 검사 성능과 계산·통신·운용 비용, 기여·크레딧·보상을 함께 고려한 참여 편익은 평가하지 못했다.

결론 및 향후 연구

- 연합모델 채택은 평균 점수와 참여자별 이득·손실을 함께 판단.
- 검출과 기준 설명은 함께 출력했으나 실제 진단 정확성은 미검증.
- 후속 과제: 반복 학습·집계, 학습 자료 확대, C3 포함·제외 비교와 비용·기여·보상 검증.

부록 안내: A1 학습·집계 / A2 참여 편익 / A3 응답·기준·검출 집계 / A4 평가 근거 / A5 선행연구 / A6 자료 분포·C3 기여·반복 집계 / R 참고문헌

[1] 한민기 외 (2025), 대한산업공학회지 51(6). [2] Yin et al. (2025), WeldLLM, ICCSN. [3] Sun et al. (2026), WeldLLM, IEEE TII 22(7).
[4] McMahan et al. (2017), AISTATS, PMLR 54. [5] Hegiste, Legler & Ruskowski (2023), Federated Object Detection for Quality Inspection in Shared Production.